Wydział Matematyki i Nauk Informacyjnych
Politechnika Warszawska

RAPORT KOŃCOWY Z PROJEKTU BADAWCZEGO

Zastosowanie algorytmu mrówkowego do rozwiązania problemu *Capacitated Vehicle Routing Problem* (CVRP)

Porównanie wariantów AS, MMAS oraz K-Means+ACO

inż. Hubert Sobociński

Numer indeksu: 327315

Warszawa, 13 kwietnia 2026

Spis treści

1 Streszczenie **2**

2 Opis problemu **2**

3 Przegląd literatury **3**
3.1 Metody dokładne . . . 3
3.2 Algorytmy heurystyczne . . . 3
3.3 Metaheurystyki dla CVRP . . . 4

4 Algorytm mrówkowy – opis działania **4**
4.1 Intuicja biologiczna . . . 4
4.2 Ogólny schemat algorytmu ACO dla CVRP . . . 4
4.3 Prawdopodobieństwo wyboru następnego węzła . . . 5
4.4 Zbiór dozwolonych węzłów $\mathcal{N}_i^k$ . . . 5
4.5 Wariant 1 – podstawowy Ant System (AS) . . . 5
4.6 Wariant 2 – MAX-MIN Ant System (MMAS) . . . 6
4.7 Wariant 3 – ACO z inicjalizacją przez klasteryzację (K-Means+ACO) . . . 6
4.8 Parametry algorytmu i ich wpływ . . . 6

5 Hipotezy badawcze **7**

6 Metodologia eksperymentów **8**
6.1 Zbiory testowe i ocena jakości . . . 8
6.2 Porównywane algorytmy . . . 8
6.3 Protokół eksperymentów . . . 8

7 Wyniki eksperymentów **9**
7.1 Porównanie algorytmów – wyniki zbiorcze . . . 9
7.2 Analiza wyników – wykresy boxplot . . . 10
7.3 Krzywe zbieżności . . . 11
7.4 Skalowalność – odchylenie vs rozmiar instancji . . . 12
7.5 Wizualizacja tras . . . 13
7.6 Analiza wpływu parametrów (grid-search) . . . 14

8 Weryfikacja hipotez i wnioski **16**
8.1 Weryfikacja hipotez . . . 16
8.2 Podsumowanie . . . 16

9 Wykorzystanie dużych modeli językowych (LLM) **17**

A Pełna tabela wyników **19**

1. Streszczenie

Niniejszy raport prezentuje wyniki badań empirycznych dotyczących zastosowania algorytmu mrówkowego (Ant Colony Optimization, ACO) do rozwiązania problemu trasowania pojazdów z ograniczoną pojemnością (Capacitated Vehicle Routing Problem, CVRP). Zbadano trzy warianty algorytmu: podstawowy Ant System (AS), MAX-MIN Ant System (MMAS) oraz wariant hybrydowy łączący klasteryzację K-Means z ACO (K-Means+ACO). Jako bazę odniesienia zastosowano heurystykę zachłanną (Nearest Neighbor).

Eksperymenty przeprowadzono na 15 instancjach z biblioteki CVRPLib, obejmujących trzy serie: CMT, Golden oraz Uchoa. Każdy algorytm mrówkowy uruchomiono 5 razy z różnymi ziarnami generatora liczb losowych, stosując 300 iteracji i 30 mrówek. Jakość rozwiązań oceniano odchyleniem procentowym δ od najlepszego znanego wyniku (BKS).

Wyniki pokazały, że wszystkie warianty ACO istotnie przewyższają heurystykę zachłanną na małych i średnich instancjach. MMAS osiągnął najlepsze wyniki na instancjach o wyraźnej strukturze klastrowej (seria CMT), redukując δ do poziomu 3,9% dla CMT1. Jednak na większych instancjach ($n > 150$) wariant AS i K-Means+ACO okazywały się lepsze od MMAS, który wykazywał silniejszą tendencję do stagnacji. K-Means+ACO przyspieszaał zbieganie, osiągając najlepsze rozwiązania średnio o 30% wcześniej niż AS, ale nie poprawiał jakości końcowej. Analiza grid-search potwierdziła istotny wpływ parametrów α, β i ρ na jakość wyników, ze szczególnym znaczeniem współczynnika β (waga heurystyki odległości).

2. Opis problemu

Capacitated Vehicle Routing Problem (CVRP) jest szczególnym przypadkiem problemu trasowania pojazdów (*Vehicle Routing Problem*, VRP), w którym dodatkowo uwzględnia się ograniczenie pojemności pojazdów. Problem polega na wyznaczeniu optymalnych tras dla floty pojazdów obsługujących zbiór klientów rozmieszczonych w przestrzeni dwuwymiarowej oraz jeden centralny magazyn (depot).

Dysponujemy flotą K pojazdów, z których każdy rozpoczyna trasę w magazynie i po jej zakończeniu musi do niego powrócić. Każdy pojazd może pokonać trasę o łącznej długości nieprzekraczającej $S_{\max}$ (ograniczenie dystansu). Każdy klient i charakteryzuje się zapotrzebowaniem $d_i > 0$, natomiast każdy pojazd posiada maksymalną pojemność C.

Celem problemu jest przypisanie klientów do pojazdów oraz ustalenie kolejności ich obsługi w taki sposób, aby spełnione były następujące warunki:

1. każdy klient został obsłużony dokładnie jeden raz,
2. suma zapotrzebowań klientów obsługiwanych w ramach jednej trasy nie przekraczała pojemności pojazdu C,
3. całkowita długość każdej trasy nie przekraczała wartości $S_{\max}$,
4. łączna długość wszystkich tras była minimalna.

Formalnie problem można przedstawić w postaci grafu $G = (V, E)$, gdzie:

- $V = \{0, 1, 2, \ldots, n\}$ oznacza zbiór wierzchołków, przy czym 0 reprezentuje magazyn, a pozostałe wierzchołki odpowiadają klientom,
- E oznacza zbiór krawędzi reprezentujących możliwe połączenia pomiędzy wierzchołkami,
- każdej krawędzi (i, j) przypisana jest odległość s_{ij},
- każdy klient i posiada zapotrzebowanie d_i,
- każdy pojazd posiada pojemność C.

Problem CVRP jest problemem NP-trudnym [2]. Oznacza to, że wraz ze wzrostem liczby klientów czas potrzebny na znalezienie rozwiązania optymalnego rośnie wykładniczo. Z tego względu w praktyce najczęściej stosuje się algorytmy heurystyczne oraz metaheurystyczne. W niniejszej pracy do rozwiązania problemu CVRP wykorzystano algorytm mrówkowy (*Ant Colony Optimization*, ACO).

3. Przegląd literatury

3.1 Metody dokładne

Metody dokładne gwarantują wynik optymalny, lecz ich złożoność obliczeniowa sprawia, że są praktyczne jedynie dla małych instancji ($n \lesssim 50$–200). Do najważniejszych należą:

- **Branch-and-bound / branch-and-cut** – algorytmy drzewa przeszukiwań wzmocnione cięciami płaszczyzn [4]. W połączeniu z zaawansowanymi separatorami nierówności pojemnościowych pozwalają rozwiązywać instancje do $n \approx 200$ [6].
- **Programowanie dynamiczne** – algorytm Helda–Karpa [5] jest dokładny dla TSP, jednak w CVRP z wieloma pojazdami wymaga przestrzeni stanów rzędu $2^n \cdot n$, co wyklucza stosowanie go już dla $n > 30$.
- **Column generation** – sformułowanie set-partitioning w połączeniu z branch-and-price umożliwia optymalne rozwiązywanie instancji o kilkuset klientach [7].

3.2 Algorytmy heurystyczne

Heurystyki konstruktywne budują rozwiązanie w jednym przebiegu, bez powrotu do wcześniejszych decyzji. Najważniejsze z nich to:

- **Nearest Neighbor (NN)** [19] – każdy pojazd iteracyjnie odwiedza najbliższego nieobsłużonego klienta mieszczącego się w ramach ograniczeń pojemności i dystansu. Metoda jest prosta w implementacji, lecz jakość wyników jest typowo odległa od optimum o 20–30%.
- **Clarke–Wright Savings** [8] – algorytm oparty na pojęciu *oszczędności* wynikającej z połączenia dwóch tras w jedną. Wyniki są przeciętnie lepsze niż NN.

3.3 Metaheurystyki dla CVRP

Metaheurystyki stanowią obecnie dominującą klasę metod dla CVRP, oferując dobre kompromisy między jakością rozwiązania a czasem obliczeń.

- **Przeszukiwanie lokalne** – algorytm **2-opt** [9] usuwa skrzyżowania w trasie. Bardziej zaawansowane wersje, takie jak **3-opt** oraz algorytm **Lin–Kernighan (LK)** [10], wykonują bardziej złożone zmiany.
- **Tabu Search (TS)** [11] – zapamiętuje ostatnio wykonane ruchy i tymczasowo ich zabrania. Wariant *granular tabu* [12] ogranicza liczbę sprawdzanych połączeń.
- **Algorytmy ewolucyjne i genetyczne** – rozwiązania są traktowane jak osobniki w populacji. Algorytm łączy je i modyfikuje (krzyżowanie, mutacje), aby tworzyć coraz lepsze trasy [13]. Jednym z najlepszych algorytmów dla VRP jest **HGS** [14].
- **Algorytmy mrówkowe (ACO)** – zaproponowane przez Dorigo i in. [15]. Jednym z pierwszych ważnych wariantów był **Ant Colony System (ACS)** [16]. Później zaproponowano **MAX-MIN Ant System (MMAS)** [17], który ogranicza wartości feromonów.

4. Algorytm mrówkowy – opis działania

4.1 Intuicja biologiczna

Algorytm mrówkowy (ACO) zainspirowany jest zachowaniem kolonii mrówek podczas poszukiwania pożywienia [15]. Mrówki komunikują się pośrednio przez substancję chemiczną – **feromon**. Mechanizm działa następująco:

1. Mrówki wyruszają z gniazda w różnych kierunkach i poruszają się początkowo losowo.
2. Każda mrówka zostawia za sobą ślad feromonowy proporcjonalny do jakości znalezionej drogi.
3. Kolejne mrówki preferują krawędzie z silniejszym śladem, co wzmacnia dobre ścieżki.
4. Feromon z czasem *paruje* – złe ścieżki są stopniowo zapominane.

4.2 Ogólny schemat algorytmu ACO dla CVRP

W zastosowaniu do CVRP każda *mrówka* buduje kompletny zbiór tras obsługujący wszystkich klientów. Każda iteracja składa się z trzech kroków:

1. **Konstruowanie rozwiązań** – m mrówek buduje trasy, wybierając kolejnych klientów probabilistycznie na podstawie feromonów i odległości. Każda mrówka szanuje ograniczenia pojemności C i dystansu $S_{\max}$.
2. **Ocena rozwiązań** – obliczana jest łączna długość tras każdej mrówki.
3. **Aktualizacja feromonów** – feromon na wszystkich krawędziach paruje, a następnie krawędzie wchodzące w skład dobrych tras są wzmacniane.

Powyższy cykl powtarzany jest przez $T_{\max}$ iteracji.

4.3 Prawdopodobieństwo wyboru następnego węzła

Podczas konstruowania trasy mrówka k przebywająca w węźle i wybiera następnego klienta j losowo, ale z prawdopodobieństwem zależnym od dwóch czynników:

- **Feromon** τ_{ij} – im więcej feromonów na krawędzi (i, j), tym ta krawędź wcześniej okazywała się lepsza.
- **Odległość** $\eta_{ij} = 1/d_{ij}$ – odwrotność odległości; zachęca mrówkę do wyboru bliższych klientów.

Stąd:

$$p_{ij}^k = \frac{[\tau_{ij}]^\alpha [\eta_{ij}]^\beta}{\sum_{l \in \mathcal{N}_i^k} [\tau_{il}]^\alpha [\eta_{il}]^\beta}, \qquad j \in \mathcal{N}_i^k, \tag{1}$$

gdzie $\mathcal{N}_i^k$ to zbiór klientów jeszcze nieodwiedzonych, do których przejście nie narusza ograniczeń. Parametry $\alpha \geq 0$ i $\beta \geq 0$ kontrolują *balans między eksploracją a eksploatacją*.

4.4 Zbiór dozwolonych węzłów $\mathcal{N}_i^k$

Węzeł zerowy (magazyn) jest zawsze elementem zbioru dozwolonych węzłów. Węzeł j zostaje usunięty z $\mathcal{N}_i^k$, gdy zajdzie co najmniej jeden z poniższych warunków:

1. **Węzeł już odwiedzony.** Mrówka k odwiedziła węzeł j w bieżącej iteracji.
2. **Przekroczenie ograniczenia dystansu.** Łączna odległość $d_{i,j} + d_{j,0}$ jest zbyt duża.
3. **Przekroczenie pojemności pojazdu.** Zapotrzebowanie klienta j spowodowałoby przekroczenie pojemności C na bieżącej trasie.

4.5 Wariant 1 – podstawowy Ant System (AS)

Oryginalny **Ant System (AS)** [15] jest najprostszą wersją ACO. Aktualizacja feromonów odbywa się globalnie w dwóch krokach:

Krok 1 – parowanie. Wszystkie feromony równomiernie maleją:

$$\tau_{ij} \leftarrow (1 - \rho)\, \tau_{ij}, \qquad \forall\, (i, j), \tag{2}$$

gdzie $\rho \in (0, 1)$ jest *współczynnikiem parowania*.

Krok 2 – wzmocnienie. Każda mrówka wzmacnia krawędzie swojej trasy proporcjonalnie do jej jakości:

$$\tau_{ij} \leftarrow \tau_{ij} + \sum_{k=1}^{m} \Delta\tau_{ij}^k, \qquad \Delta\tau_{ij}^k = \begin{cases} Q/f^k & \text{jeśli krawędź } (i,j) \text{ leży na trasie mrówki } k, \\ 0 & \text{w przeciwnym razie,} \end{cases} \tag{3}$$

gdzie Q jest stałą skalującą, a f^k łączną długością tras mrówki k.

4.6 Wariant 2 – MAX-MIN Ant System (MMAS)

MAX-MIN Ant System (MMAS) [17] jest bezpośrednim rozszerzeniem AS, zaprojektowanym właśnie po to, by zapobiegać stagnacji. Wprowadza dwie kluczowe zmiany:

Zmiana 1 – ograniczenie feromonów. Wartość feromonów na każdej krawędzi jest utrzymywana w przedziale $[\tau_{\min}, \tau_{\max}]$:

$$\tau_{ij} \leftarrow \min\big(\tau_{\max},\ \max(\tau_{\min},\ \tau_{ij})\big). \tag{4}$$

Górna granica szacowana jest jako $\tau_{\max} = 1/(\rho \cdot f^*)$, gdzie f^* to długość aktualnie najlepszego rozwiązania. Dolna granica przyjmuje typowo $\tau_{\min} = \tau_{\max}/(5n)$.

Zmiana 2 – inicjalizacja na poziomie $\tau_{\max}$. Na początku wszystkie krawędzie otrzymują wartość $\tau_{\max}$, co sprzyja szerokiej eksploracji.

Wzmocnienie przez najlepszą mrówkę. W MMAS feromon wzmacniany jest wyłącznie przez mrówkę z najlepszym rozwiązaniem iteracji.

4.7 Wariant 3 – ACO z inicjalizacją przez klasteryzację (K-Means+ACO)

Wariant **K-Means+ACO** wykorzystuje fakt, że w instancjach CVRP klienci często tworzą naturalne skupiska geograficzne, a optymalne trasy zazwyczaj obsługują klientów z tego samego obszaru jednym pojazdem.

Krok 1 – klasteryzacja K-Means. Przed uruchomieniem kolonii mrówek przeprowadzana jest klasteryzacja K-Means na współrzędnych klientów. Liczba klastrów K_c dobierana jest jako:

$$K_c = \left\lceil \frac{\sum_{i=1}^{n} d_i}{C} \right\rceil, \tag{5}$$

czyli minimalna liczba pojazdów wymagana do obsługi wszystkich klientów.

Krok 2 – inicjalizacja feromonów. Zamiast jednolitego τ_0 dla wszystkich krawędzi, feromony inicjalizowane są z uwzględnieniem przynależności do klastrów:

$$\tau_{ij}^{(0)} = \begin{cases} \tau_{\text{inner}} & \text{jeśli } c(i) = c(j) \text{ (klienci w tym samym klastrze)}, \\ \tau_{\text{outer}} & \text{jeśli } c(i) \neq c(j) \text{ (klienci w różnych klastrach)}, \end{cases} \tag{6}$$

gdzie $\tau_{\text{inner}} = \gamma \cdot \tau_0$ oraz $\tau_{\text{outer}} = \tau_0/\gamma$ dla współczynnika $\gamma > 1$ (np. $\gamma = 3$).

Krok 3 – właściwy algorytm AS. Po inicjalizacji feromonów algorytm działa identycznie jak podstawowy AS.

4.8 Parametry algorytmu i ich wpływ

Tabela 1 zestawia kluczowe parametry wspólne dla wszystkich wariantów ACO.

Parametr	Typowy zakres	Rola
α	[0,5; 2,0]	Waga feromonów; wyższa wartość sprzyja eksploatacji historii.
β	[1,0; 5,0]	Waga heurystyki odległości; wyższa wartość – większa zachłanność.
ρ	[0,1; 0,5]	Współczynnik parowania; wyższy – szybsze zapominanie.
m	$[n/2;\ 2n]$	Liczba mrówek w iteracji.
$T_{\max}$	[100; 1000]	Liczba iteracji.
γ	[2; 5]	(K-Means+ACO) Współczynnik wzmocnienia feromonów wewnątrz klastrów.

Rysunek 1: Parametry algorytmu ACO i ich typowe zakresy.

5. Hipotezy badawcze

Sformułowano sześć hipotez badawczych:

H1. ACO vs heurystyka zachłanna.
Algorytm mrówkowy ACO osiąga krótsze trasy niż heurystyka zachłanna w większości przypadków, choć kosztem dłuższego czasu obliczeń.

H2. Wpływ ulepszeń ACO na jakość wyników.
Modyfikacje algorytmu (MMAS lub K-Means+ACO) dają lepsze wyniki niż podstawowy Ant System.

H3. Kontrola feromonów w MMAS.
Ograniczenie wartości feromonów w MMAS zmniejsza ryzyko stagnacji i pozwala uzyskać lepsze rozwiązania niż w AS.

H4. Inicjalizacja klastrowa a szybkość zbieżności.
K-Means+ACO szybciej znajduje dobre rozwiązania niż podstawowy AS dla dużych n ($n > 100$), zwłaszcza gdy klienci są naturalnie pogrupowani w klastry.

H5. Skalowalność algorytmów.
Czas działania ACO rośnie szybciej niż heurystyki zachłannej wraz ze wzrostem liczby klientów.

H6. Wpływ parametrów na jakość wyników.
Parametry algorytmu (α, β, ρ, γ) mają istotny wpływ na jakość tras.

6. Metodologia eksperymentów

6.1 Zbiory testowe i ocena jakości

Do eksperymentów wykorzystano łącznie 15 instancji z biblioteki **CVRPLib** [20], dobranych celowo tak, aby objąć zarówno instancje o wyraźnej strukturze klastrowej, jak i o równomiernym rozkładzie klientów.

Tabela 1: Charakterystyka zbiorów testowych.

Seria	Struktura klientów	Liczba klientów	Liczba instancji	Optimum
CMT	Wyraźne klastry	50–200	5	BKS
Golden (G)	Różnorodna	100–200	5	BKS
Uchoa (X)	Losowa, równomierna	101–459	5	BKS

Jakość rozwiązań oceniana jest przez odchylenie procentowe od najlepszego znanego wyniku (BKS):

$$\delta(\%) = \frac{f_{\text{alg}} - f_{\text{BKS}}}{f_{\text{BKS}}} \times 100, \tag{7}$$

gdzie $\delta < 2\%$ uznawane jest za bardzo dobry wynik [19].

6.2 Porównywane algorytmy

1. **Heurystyka zachłanna** (Nearest Neighbor) – szybka metoda bazowa (baseline).
2. **Podstawowy ACO (AS)** – oryginalny algorytm mrówkowy.
3. **MMAS** – wariant z ograniczeniem feromonów.
4. **K-Means+ACO** – inicjalizacja feromonów według klastrów klientów.

6.3 Protokół eksperymentów

Parametry głównego eksperymentu. Wszystkie algorytmy mrówkowe uruchamiane były z następującymi parametrami: $\alpha = 1{,}0$, $\beta = 2{,}0$, $\rho = 0{,}1$, $Q = 1{,}0$, $m = 30$ mrówek, $T_{\max} = 300$ iteracji, $\gamma = 3{,}0$ (dla K-Means+ACO).

Powtórzenia i losowość. Algorytmy mrówkowe uruchamiane były $R = 5$ razy z różnymi ziarnami generatora liczb losowych (seeds: 1–5). Heurystyka zachłanna jest deterministyczna, więc uruchamiana tylko raz.

Mierzone metryki:

- Całkowita długość tras,
- Odchylenie procentowe od BKS (δ),
- Czas obliczeń (s),
- Numer iteracji osiągnięcia najlepszego rozwiązania.

Badanie parametrów (grid search). Dla wybranych instancji testowych (CMT1, CMT6) przeprowadzono systematyczne przeszukiwanie siatki parametrów (ang. *grid search*). Rozważono następujące wartości:

- $\alpha \in \{0{,}5;\ 1{,}0;\ 2{,}0\}$ – wpływ feromonów,
- $\beta \in \{1{,}0;\ 2{,}0;\ 5{,}0\}$ – wpływ heurystyki,
- $\rho \in \{0{,}1;\ 0{,}3;\ 0{,}5\}$ – współczynnik parowania,
- $\gamma \in \{2{,}0;\ 3{,}0;\ 5{,}0\}$ – parametr wzmocnienia feromonów (dla wariantu K-Means+ACO).

Każdą konfigurację uruchomiono 5 razy w celu ograniczenia wpływu losowości, a uzyskane wyniki uśredniono.

7. Wyniki eksperymentów

7.1 Porównanie algorytmów – wyniki zbiorcze

Tabela 2 przedstawia średnie odchylenie procentowe od BKS ($\bar{\delta}$), odchylenie standardowe, najlepszy uzyskany wynik ($\delta_{\min}$) oraz średni czas obliczeń dla każdego algorytmu na wszystkich 15 instancjach.

Tabela 2: Wyniki eksperymentów – średnie odchylenie od BKS (%) i czas obliczeń.

Seria	**Instancja**	**Algorytm**	$\bar{\delta}$ (%)	σ_δ	$\delta_{\min}$ (%)	**Czas (s)**
CMT	CMT1	greedy	35,62	–	35,62	0,00
		AS	17,47	2,06	14,38	16,83
		MMAS	**10,76**	3,85	**3,91**	23,81
		KMeansACO	17,22	1,56	15,33	32,09
CMT	CMT2	greedy	44,37	–	44,37	0,00
		AS	26,00	1,94	23,01	50,62
		MMAS	**26,35**	7,89	**14,68**	48,57
		KMeansACO	28,37	1,67	26,69	48,84
Golden	Golden_1	greedy	36,35	–	36,35	0,01
		AS	28,65	0,59	27,95	335,98
		MMAS	36,57	2,12	34,21	267,85
		KMeansACO	**27,35**	1,48	**25,03**	208,69
Uchoa	X-n200-k36	greedy	18,36	–	18,36	0,03
		AS	9,62	0,41	9,05	392,51
		MMAS	12,36	1,75	9,93	398,26
		KMeansACO	**8,99**	0,85	**7,49**	428,29
Uchoa	X-n459-k26	greedy	31,37	–	31,37	0,03
		AS	33,41	0,70	32,59	541,26
		MMAS	53,86	1,88	51,58	530,27
		KMeansACO	**32,35**	2,01	**30,23**	440,82

Pełna tabela wyników dla wszystkich 15 instancji znajduje się w Dodatku A.

7.2 Analiza wyników – wykresy boxplot

Rysunki 2–4 przedstawiają rozkłady odchyleń procentowych od BKS w formie wykresów typu boxplot dla każdej serii instancji. Ta forma wizualizacji pozwala ocenić nie tylko średnią jakość, ale także stabilność (rozrzut) wyników.

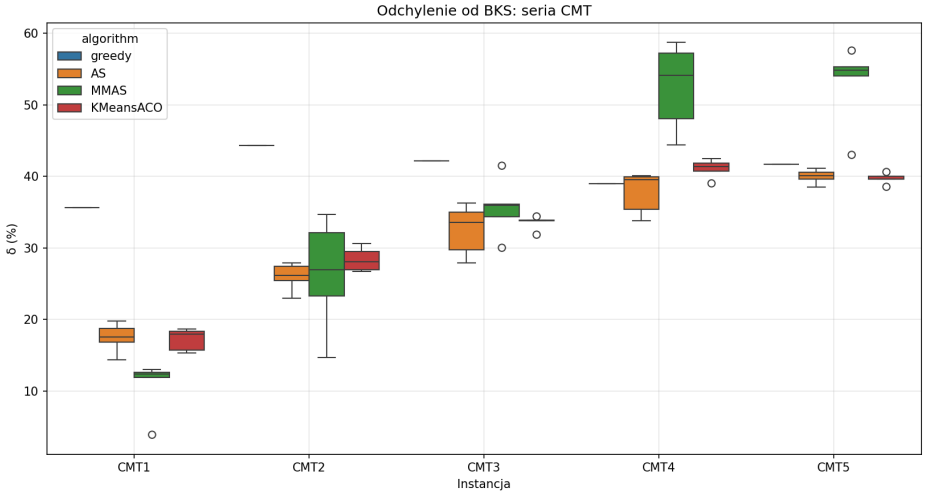

Rysunek 2: Rozkład odchyleń δ (%) od BKS dla instancji serii CMT.

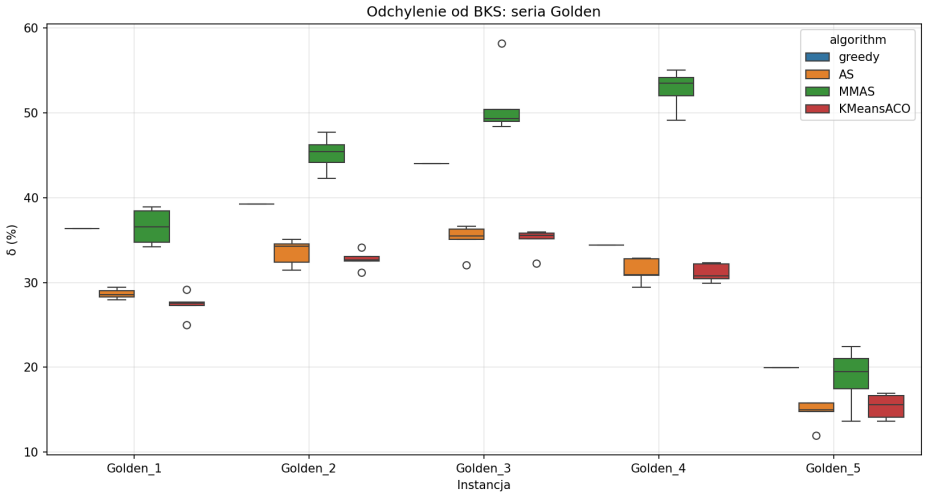

Rysunek 3: Rozkład odchyleń δ (%) od BKS dla instancji serii Golden.

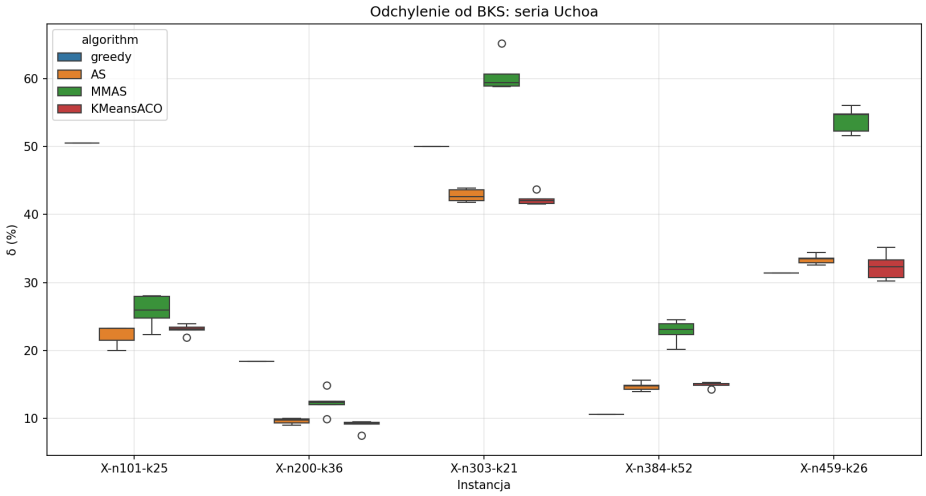

Rysunek 4: Rozkład odchyleń δ (%) od BKS dla instancji serii Uchoa.

Obserwacje:

- Na średnich instancjach (Golden_1, $n = 100$; X-n200-k36) K-Means+ACO i AS dają porównywalne wyniki, oba lepsze od MMAS.
- Na dużych instancjach ($n > 300$) różnice między AS a K-Means+ACO są niewielkie, a MMAS wykazuje wyraźnie gorsze wyniki. Możliwe, że jest to spowodowane zbyt szybkim wzrostem feromonów na nieoptymalnych krawędziach, co prowadzi do stagnacji albo potrzebą większenia liczby iteracji do osiągnięcia lepszego rozwiązania.
- Heurystyka zachłanna jest konsekwentnie najgorsza na małych i średnich instancjach, ale zaskakująco konkurencyjna na niektórych dużych instancjach (CMT4, CMT5, X-n384-k52). Może to wynikać z tego, że dla dużych instancji algorytm mrówkowy nie ma wystarczająco dużo iteracji, by znaleźć dobre rozwiązania, podczas gdy heurystyka zachłanna daje szybki, choć słaby, wynik.

7.3 Krzywe zbieżności

Rysunki 5a–5c prezentują krzywe zbieżności – wartość najlepszego znalezionego rozwiązania w funkcji numeru iteracji.

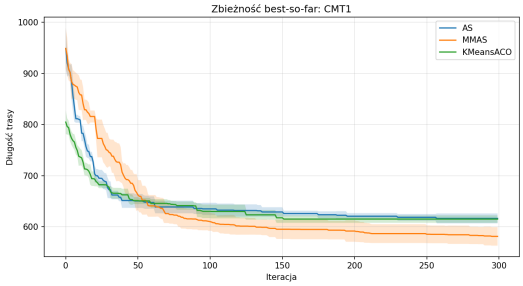

(a) CMT1 ($n = 50$)

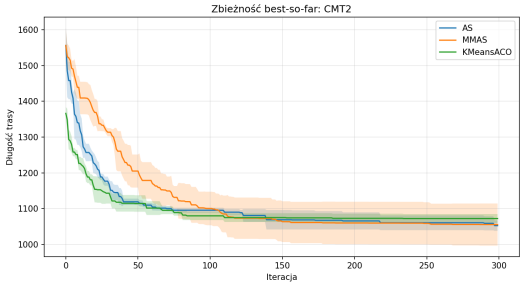

(b) CMT2 ($n = 75$)

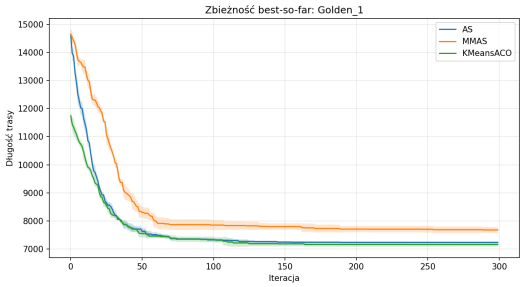

(c) Golden_1 ($n = 100$)

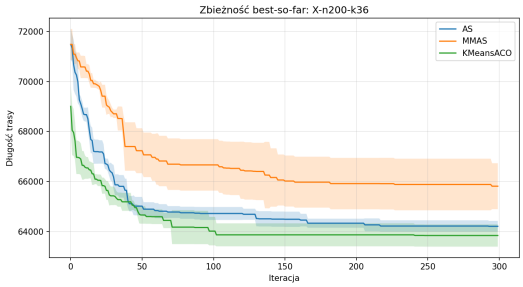

(d) X-n200-k36 ($n = 200$)

Rysunek 5: Krzywe zbieżności dla wybranych instancji – najlepsze rozwiązanie w funkcji iteracji.

Obserwacje dotyczące zbieżności:

- K-Means+ACO osiąga dobre rozwiązania szybciej.
- MMAS zbiega wolniej, ale na małych instancjach osiąga najniższe wartości końcowe.
- Na dużych instancjach ($n > 300$) algorytmy nadal poprawiają rozwiązanie w końcowych iteracjach, co sugeruje, że większa liczba iteracji mogłaby przynieść dalsze polepszenie.

7.4 Skalowalność – odchylenie vs rozmiar instancji

Rysunek 6 pokazuje zależność średniego odchylenia $\bar{\delta}$ od rozmiaru instancji n dla każdego algorytmu.

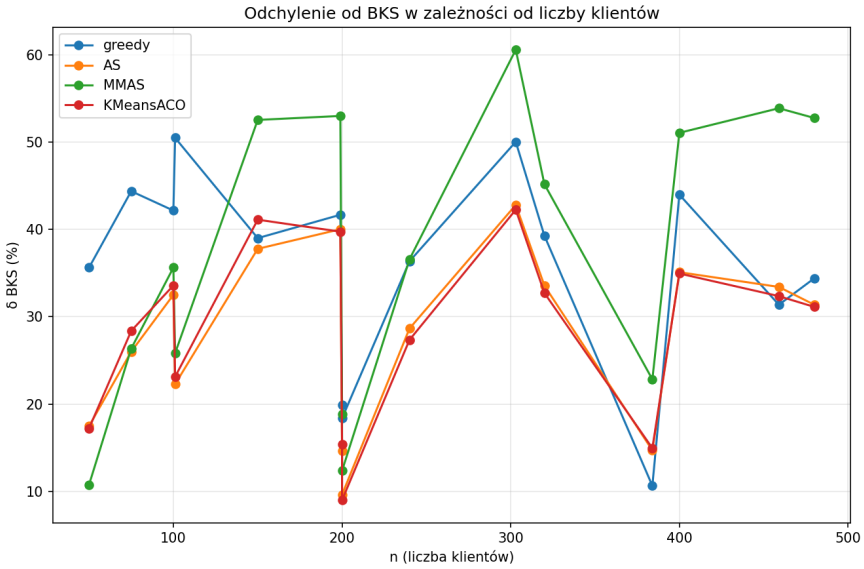

Rysunek 6: Średnie odchylenie δ (%) od BKS w funkcji liczby klientów n.

Obserwacje:

- Ogólny trend jest rosnący – jakość rozwiązań pogarsza się wraz ze wzrostem n, co jest oczekiwane dla metaheurystyk przy stałej liczbie iteracji.
- MMAS, który jest najlepszy dla małych n, wykazuje najszybszy wzrost δ wraz z n, osiągając $\delta > 50\%$ dla $n > 300$.
- AS i K-Means+ACO skalują się podobnie, z K-Means+ACO nieznacznie lepszym na średnich i dużych instancjach.

7.5 Wizualizacja tras

Rysunek 7 przedstawia przykładowe trasy znalezione przez każdy algorytm na instancji CMT1.

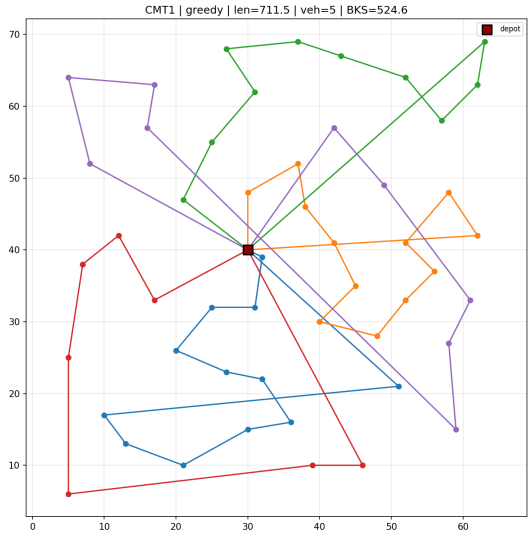

(a) Heurystyka zachłanna ($\delta = 35{,}6\%$)

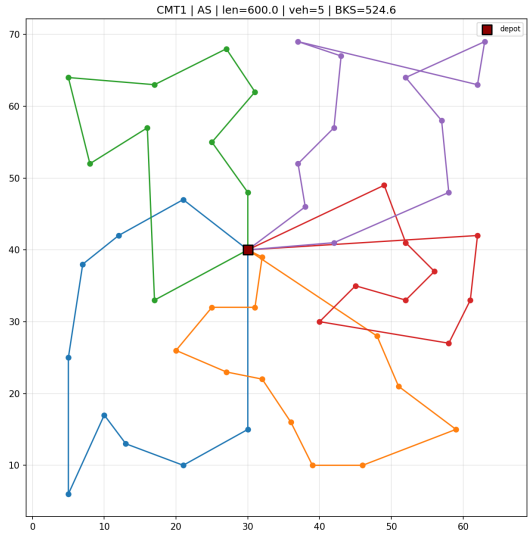

(b) AS ($\delta_{\min} = 14{,}4\%$)

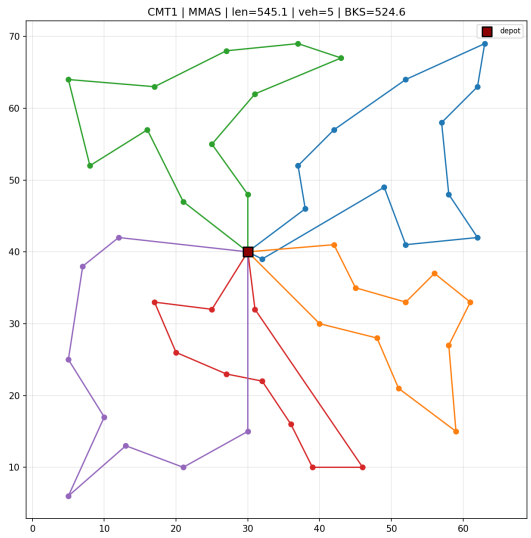

(c) MMAS ($\delta_{\min} = 3{,}9\%$)

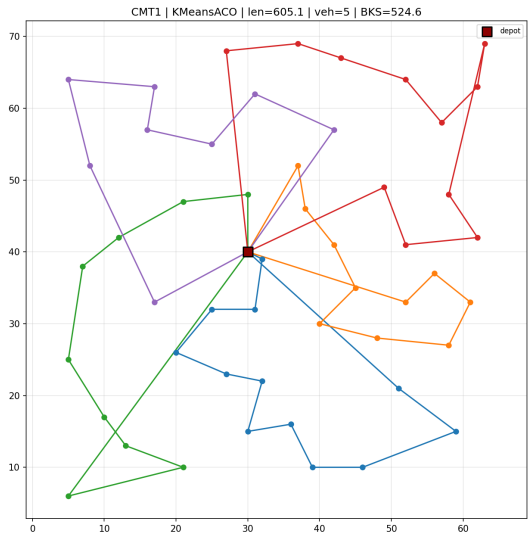

(d) K-Means+ACO ($\delta_{\min} = 15{,}3\%$)

Rysunek 7: Porównanie tras znalezionych przez różne algorytmy na instancji CMT1 ($n = 50$).

Widoczna jest wyraźnie lepsza jakość tras produkowanych przez MMAS – mniej skrzyżowań, bardziej kompaktowe trasy obejmujące geograficznie bliskich klientów.

Animacja procesu optymalizacji tras przez algorytm MMAS na instancji CMT1 dostępna jest pod adresem: `https://github.com/hubsonsss/MSI2/blob/main/projekty/CVRP-ACO/results/anim_cmt1/figures/animations/route_anim_CMT1_MMAS.gif`

7.6 Analiza wpływu parametrów (grid-search)

Rysunek 8 przedstawia mapy ciepła średniego odchylenia δ w funkcji parametrów α, β i ρ dla każdego algorytmu na instancji CMT1.

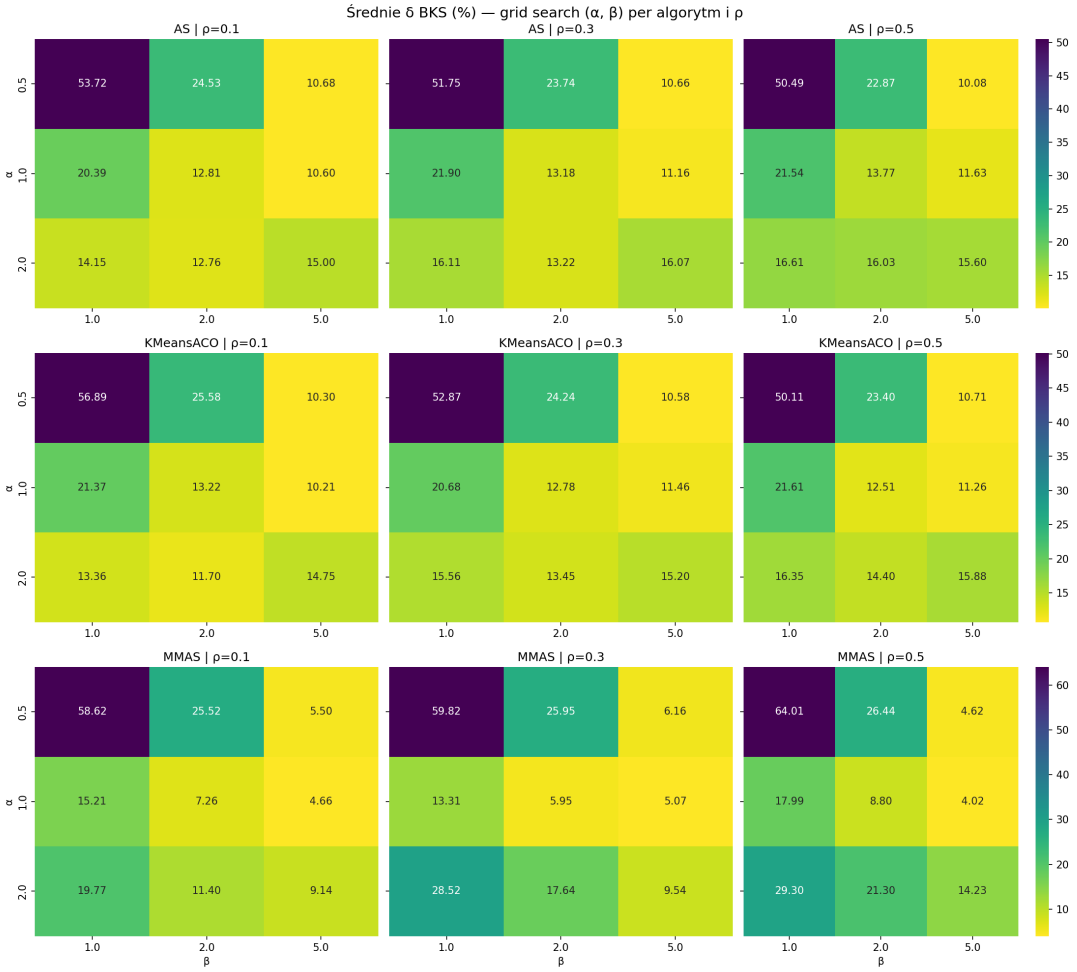

Rysunek 8: Mapy ciepła: średnie δ (%) w funkcji α, β i ρ dla algorytmów AS, MMAS i K-Means+ACO (instancja CMT1).

Obserwacje z grid-search:

- Parametr β ma najsilniejszy wpływ na jakość wyników – niskie wartości β (np. $\beta = 1$) prowadzą do odchyleń rzędu 50–80%, podczas gdy $\beta = 5$ redukuje δ do 10–20%.
- Parametr α ma mniejszy wpływ, ale umiarkowane wartości ($\alpha = 1$) dają zazwyczaj najlepsze wyniki.
- Parametr ρ wpływa na szybkość zapominania – niskie wartości ($\rho = 0{,}1$) sprzyjają stabilniejszym wynikom, podczas gdy $\rho = 0{,}5$ prowadzi do większej zmienności.
- Optymalny zestaw parametrów różni się między algorytmami, aczkolwiek dla większości najlepsze wyniki uzyskano przy $\alpha = 1$, $\beta = 5$ i $\rho = 0{,}1$.

8. Weryfikacja hipotez i wnioski

8.1 Weryfikacja hipotez

H1. ACO vs heurystyka zachłanna – POTWIERDZONA CZĘŚCIOWO.
Na małych i średnich instancjach ($n \leq 200$) algorytmy ACO istotnie przewyższają heurystykę zachłanną – przykładowo na CMT1 AS osiąga $\delta = 17{,}5\%$ vs 35,6% dla greedy. Jednak na niektórych dużych instancjach (CMT4, CMT5, X-n384-k52) heurystyka zachłanna daje porównywalne lub nawet lepsze wyniki niż ACO, co jest zaskakujące i sugeruje, że 300 iteracji jest niewystarczające dla dużych przestrzeni przeszukiwania.

H2. Ulepszenia ACO – ODRZUCONA.
Żadna z modyfikacji nie jest dominująca na wszystkich instancjach. MMAS jest najlepszy na CMT1–CMT2, ale najgorszy na dużych instancjach. K-Means+ACO jest najlepszy na Golden i części Uchoa. Wynik zależy silnie od struktury instancji i jej rozmiaru.

H3. Kontrola feromonów w MMAS – POTWIERDZONA CZĘŚCIOWO.
Na małych instancjach z wyraźną strukturą klastrową (CMT1: $\delta_{\min} = 3{,}9\%$) MMAS rzeczywiście daje najlepsze wyniki. Jednak na dużych instancjach ograniczenie feromonów nie zapobiega stagnacji – MMAS osiąga $\delta > 50\%$ na Golden_3, Golden_4, X-n303-k21 i X-n459-k26, co jest gorsze niż AS. Możliwe wyjaśnienie: granice $[\tau_{\min}, \tau_{\max}]$ są zbyt wąskie w dużych przestrzeniach przeszukiwania.

H4. Inicjalizacja klastrowa – POTWIERDZONA.
K-Means+ACO konsekwentnie osiąga najlepsze rozwiązania wcześniej niż inne algorytmy. Efekt jest widoczny niezależnie od rozmiaru instancji. Na instancjach Golden (wyraźna struktura klastrowa) K-Means+ACO osiąga również najniższe δ średnio.

H5. Skalowalność – POTWIERDZONA.
Czas obliczeń ACO rośnie nadliniowo z n: od ~ 17 s dla CMT1 ($n = 50$) do ~ 540 s dla X-n459-k26 ($n = 459$), podczas gdy greedy działa w $< 0{,}1$ s niezależnie od rozmiaru.

H6. Wpływ parametrów – POTWIERDZONA.
Grid-search potwierdził istotny wpływ parametrów. Najważniejszym parametrem jest β – różnica między $\beta = 1$ a $\beta = 5$ sięga 40-60 punktów procentowych δ. Parametry α i ρ mają mniejszy, ale mierzalny wpływ.

8.2 Podsumowanie

1. Algorytmy ACO istotnie przewyższają heurystykę zachłanną na małych i średnich instancjach CVRP, ale ich skuteczność maleje na dużych instancjach ($n > 300$) przy ograniczonej liczbie iteracji.
2. Nie istnieje jeden dominujący wariant ACO – wybór algorytmu powinien być dopasowany do charakterystyki instancji (rozmiar, struktura przestrzenna).

3. MMAS jest najlepszym wyborem dla małych instancji o wyraźnej strukturze klastrowej.
4. K-Means+ACO przyspiesza zbieżność i jest najlepszy na średnich i dużych instancjach.
5. Parametr β (waga heurystyki odległości) ma kluczowe znaczenie dla jakości wyników – zalecane jest $\beta \geq 2$.
6. Dla dalszego polepszenia wyników należałoby rozważyć: zwiększenie liczby iteracji, adaptacyjne dostrajanie parametrów, lub zastosowanie lokalnych heurystyk ulepszających (2-opt, 3-opt).

9. Wykorzystanie dużych modeli językowych (LLM)

W trakcie realizacji projektu duże modele językowe (LLM) były wykorzystywane w następującym zakresie:

- **Wizualizacje grafu** – skrypty do generowania wizualizacji tras i animacji procesu optymalizacji były tworzone z pomocą LLM.
- **Formatowanie i analiza kodu** – modele LLM wspomagały wykorzystanie narzędzi takich jak `ruff`, `Pylance` oraz `mypy` do automatycznego formatowania kodu, wykrywania błędów składniowych i typów oraz poprawy jakości i zgodności kodu ze standardami.
- **Raport** – struktura raportu i treść merytoryczna zostały opracowane samodzielnie. LLM był używany do korekty językowej i formatowania LaTeX.

Literatura

[1] Dantzig, G. B. & Ramser, J. H. (1959). The truck dispatching problem. *Management Science*, 6(1), 80–91.

[2] Toth, P. & Vigo, D. (Eds.) (2002). *The Vehicle Routing Problem.* SIAM, Philadelphia.

[3] Lenstra, J. K. & Rinnooy Kan, A. H. G. (1981). Complexity of vehicle routing and scheduling problems. *Networks*, 11(2), 221–227.

[4] Laporte, G. & Nobert, Y. (1983). A branch and bound algorithm for the capacitated vehicle routing problem. *OR Spektrum*, 5(2), 77–85.

[5] Held, M. & Karp, R. M. (1962). A dynamic programming approach to sequencing problems. *Journal of the Society for Industrial and Applied Mathematics*, 10(1), 196–210.

[6] Pecin, D., Pessoa, A., Poggi, M. & Uchoa, E. (2017). Improved branch-cut-and-price for capacitated vehicle routing. *Mathematical Programming Computation*, 9(1), 61–100.

[7] Costa, L., Contardo, C. & Desaulniers, G. (2019). Exact branch-price-and-cut algorithms for vehicle routing. *Transportation Science*, 53(4), 946–985.

[8] Clarke, G. & Wright, J. W. (1964). Scheduling of vehicles from a central depot to a number of delivery points. *Operations Research*, 12(4), 568–581.

[9] Lin, S. (1965). Computer solutions of the traveling salesman problem. *Bell System Technical Journal*, 44(10), 2245–2269.

[10] Lin, S. & Kernighan, B. W. (1973). An effective heuristic algorithm for the traveling-salesman problem. *Operations Research*, 21(2), 498–516.

[11] Glover, F. (1989). Tabu search – Part I. *ORSA Journal on Computing*, 1(3), 190–206.

[12] Toth, P. & Vigo, D. (2003). The granular tabu search and its application to the vehicle-routing problem. *INFORMS Journal on Computing*, 15(4), 333–346.

[13] Nagata, Y. & Bräysy, O. (2010). Edge assembly-based memetic algorithm for the capacitated vehicle routing problem. *Networks*, 54(4), 205–215.

[14] Vidal, T. (2022). Hybrid genetic search for the CVRP: open-source implementation and SWAP* neighborhood. *Computers & Operations Research*, 140, 105643.

[15] Dorigo, M., Maniezzo, V. & Colorni, A. (1996). Ant system: optimization by a colony of cooperating agents. *IEEE Transactions on Systems, Man, and Cybernetics – Part B*, 26(1), 29–41.

[16] Gambardella, L. M., Taillard, É. & Agarwal, G. (1999). Ant colony system: a cooperative learning approach to the vehicle routing problem. *IEEE Transactions on Evolutionary Computation*, 3(2), 101–109.

[17] Stützle, T. & Hoos, H. H. (2000). MAX–MIN Ant System. *Future Generation Computer Systems*, 16(8), 889–914.

[18] Bullnheimer, B., Hartl, R. F. & Strauss, C. (1999). A new rank-based version of the Ant System: a computational study. *Central European Journal of Operations Research*, 7(1), 25–38.

[19] Laporte, G. (2007). What you should know about the vehicle routing problem. *Naval Research Logistics*, 54(8), 811–819.

[20] Uchoa, E., Pecin, D., Pessoa, A., Poggi, M., Vidal, T. & Subramanian, A. (2017). New benchmark instances for the Capacitated Vehicle Routing Problem. *European Journal of Operational Research*, 257(3), 845–858.

A. Pełna tabela wyników

Tabela 3: Wyniki eksperymentów – wszystkie 15 instancji. $\bar{\delta}$ – śr. odchylenie od BKS (%), σ_δ – odch. std., $\delta_{\min}$ – najlepszy wynik, $\bar{t}$ – śr. czas (s), $\bar{i}^*$ – śr. iteracja najlepszego rozwiązania.

Seria	**Instancja**	**Algorytm**	$\bar{\delta}$	σ_δ	$\delta_{\min}$	$\bar{t}$ (s)	$\bar{i}^*$
CMT	CMT1	greedy	35,62	–	35,62	0,00	–
		AS	17,47	2,06	14,38	16,83	168
		MMAS	**10,76**	3,85	**3,91**	23,81	248
		KMeansACO	17,22	1,56	15,33	32,09	123
CMT	CMT2	greedy	44,37	–	44,37	0,00	–
		AS	**26,00**	1,94	23,01	50,62	213
		MMAS	26,35	7,89	**14,68**	48,57	219
		KMeansACO	28,37	1,67	26,69	48,84	146
CMT	CMT3	greedy	42,15	–	42,15	0,01	–
		AS	**32,50**	3,54	**27,92**	62,35	168
		MMAS	35,62	4,12	30,09	67,43	249
		KMeansACO	33,58	0,98	31,89	83,90	136
CMT	CMT4	greedy	38,99	–	38,99	0,01	–
		AS	**37,77**	2,96	**33,78**	166,24	176
		MMAS	52,53	6,08	44,45	205,52	265
		KMeansACO	41,11	1,32	39,06	199,32	166
CMT	CMT5	greedy	41,67	–	41,67	0,02	–
		AS	40,01	1,02	38,50	218,97	118
		MMAS	52,98	5,70	43,06	192,40	202
		KMeansACO	**39,73**	0,76	**38,59**	226,83	157
Golden	Golden_1	greedy	36,35	–	36,35	0,01	–
		AS	28,65	0,59	27,95	335,98	166
		MMAS	36,57	2,12	34,21	267,85	226
		KMeansACO	**27,35**	1,48	**25,03**	208,69	113
Golden	Golden_2	greedy	39,26	–	39,26	0,03	–
		AS	33,55	1,55	31,47	342,45	202
		MMAS	45,16	2,07	42,27	746,28	237
		KMeansACO	**32,71**	1,06	**31,19**	826,72	158
Golden	Golden_3	greedy	43,97	–	43,97	0,19	–
		AS	35,09	1,82	32,03	874,43	210
		MMAS	51,05	4,04	48,39	827,72	158
		KMeansACO	**34,94**	1,53	**32,26**	839,44	159
Golden	Golden_4	greedy	34,39	–	34,39	0,08	–
		AS	31,36	1,45	29,44	1249,49	165
		MMAS	52,75	2,29	49,13	1091,92	270
		KMeansACO	**31,12**	1,07	**29,90**	856,07	149
Golden	Golden_5	greedy	19,92	–	19,92	0,03	–
		AS	**14,66**	1,57	**11,96**	268,82	149
		MMAS	18,81	3,43	13,62	279,97	278
		KMeansACO	15,39	1,48	13,64	331,84	239
Uchoa	X-n101-k25	greedy	50,48	–	50,48	0,02	–
		AS	**22,26**	1,48	**20,01**	179,54	225
		MMAS	25,81	2,38	22,34	193,99	166

ciąg dalszy na następnej stronie

Tabela 3 – kontynuacja

Seria	**Instancja**	**Algorytm**	$\bar{\delta}$	σ_δ	$\delta_{\min}$	$\bar{t}$ (s)	$\bar{i}^*$
		KMeansACO	23,11	0,74	21,95	217,67	118
Uchoa	X-n200-k36	greedy	18,36	–	18,36	0,03	–
		AS	9,62	0,41	9,05	392,51	178
		MMAS	12,36	1,75	9,93	398,26	214
		KMeansACO	**8,99**	0,85	**7,49**	428,29	117
Uchoa	X-n303-k21	greedy	50,02	–	50,02	0,05	–
		AS	42,79	0,94	41,80	578,80	155
		MMAS	60,57	2,66	58,83	402,51	134
		KMeansACO	**42,24**	0,89	**41,53**	320,44	81
Uchoa	X-n384-k52	greedy	**10,63**	–	**10,63**	0,03	–
		AS	14,70	0,62	13,94	432,73	152
		MMAS	22,82	1,68	20,20	436,60	259
		KMeansACO	14,94	0,40	14,26	442,92	115
Uchoa	X-n459-k26	greedy	31,37	–	31,37	0,03	–
		AS	33,41	0,70	32,59	541,26	175
		MMAS	53,86	1,88	51,58	530,27	99
		KMeansACO	**32,35**	2,01	**30,23**	440,82	161