METODY WYJAŚNIALNOŚCI MODELI AI

GradCAM · LIME · SHAP

Politechnika Warszawska
Wydział Matematyki
i Nauk Informacyjnych

Hubert Sobociński

Źródła: Ribeiro et al. (KDD 2016) · Selvaraju et al. (ICCV 2017) · Lundberg & Lee (NeurIPS 2017)

PROBLEM CZARNYCH SKRZYNEK

WYSOKA DOKŁADNOŚĆ VS **WYSOKA INTERPRETOWALNOŚĆ**

- MEDYCYNA
- FINANSE I BANKOWOŚĆ
- SYSTEMY AUTONOMICZNE
- SĄDOWNICTWO
- DEBUGGING MODELI

GRADCAM

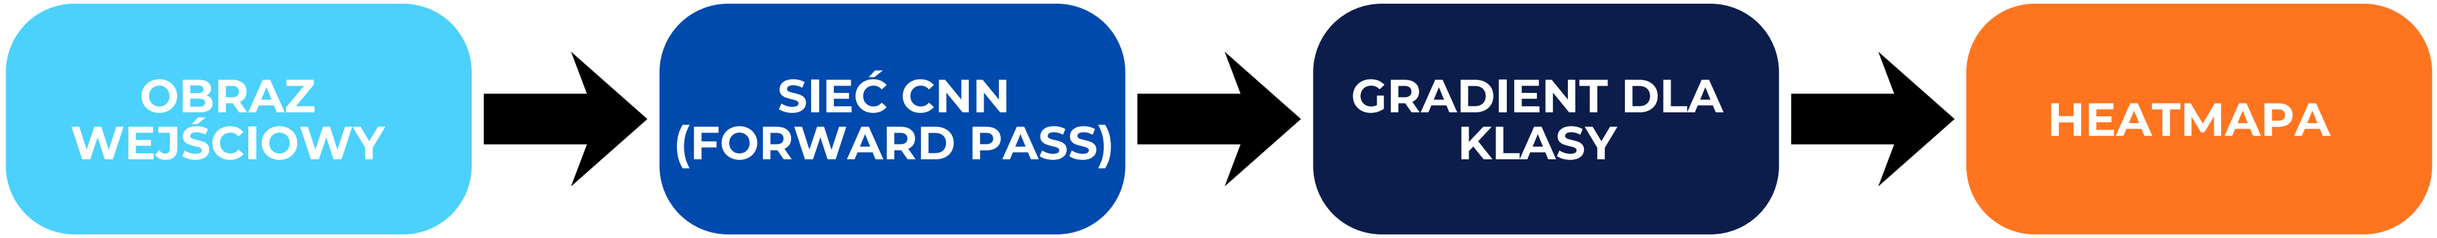

$$\alpha_k^c = \overbrace{\frac{1}{Z}\sum_i\sum_j}^{\text{global average pooling}} \underbrace{\frac{\partial y^c}{\partial A_{ij}^k}}_{\text{gradients via backprop}}$$

$$L_{Grad-CAM}^c = ReLU\left(\sum_k a_k^c A^k\right)$$

GRADCAM

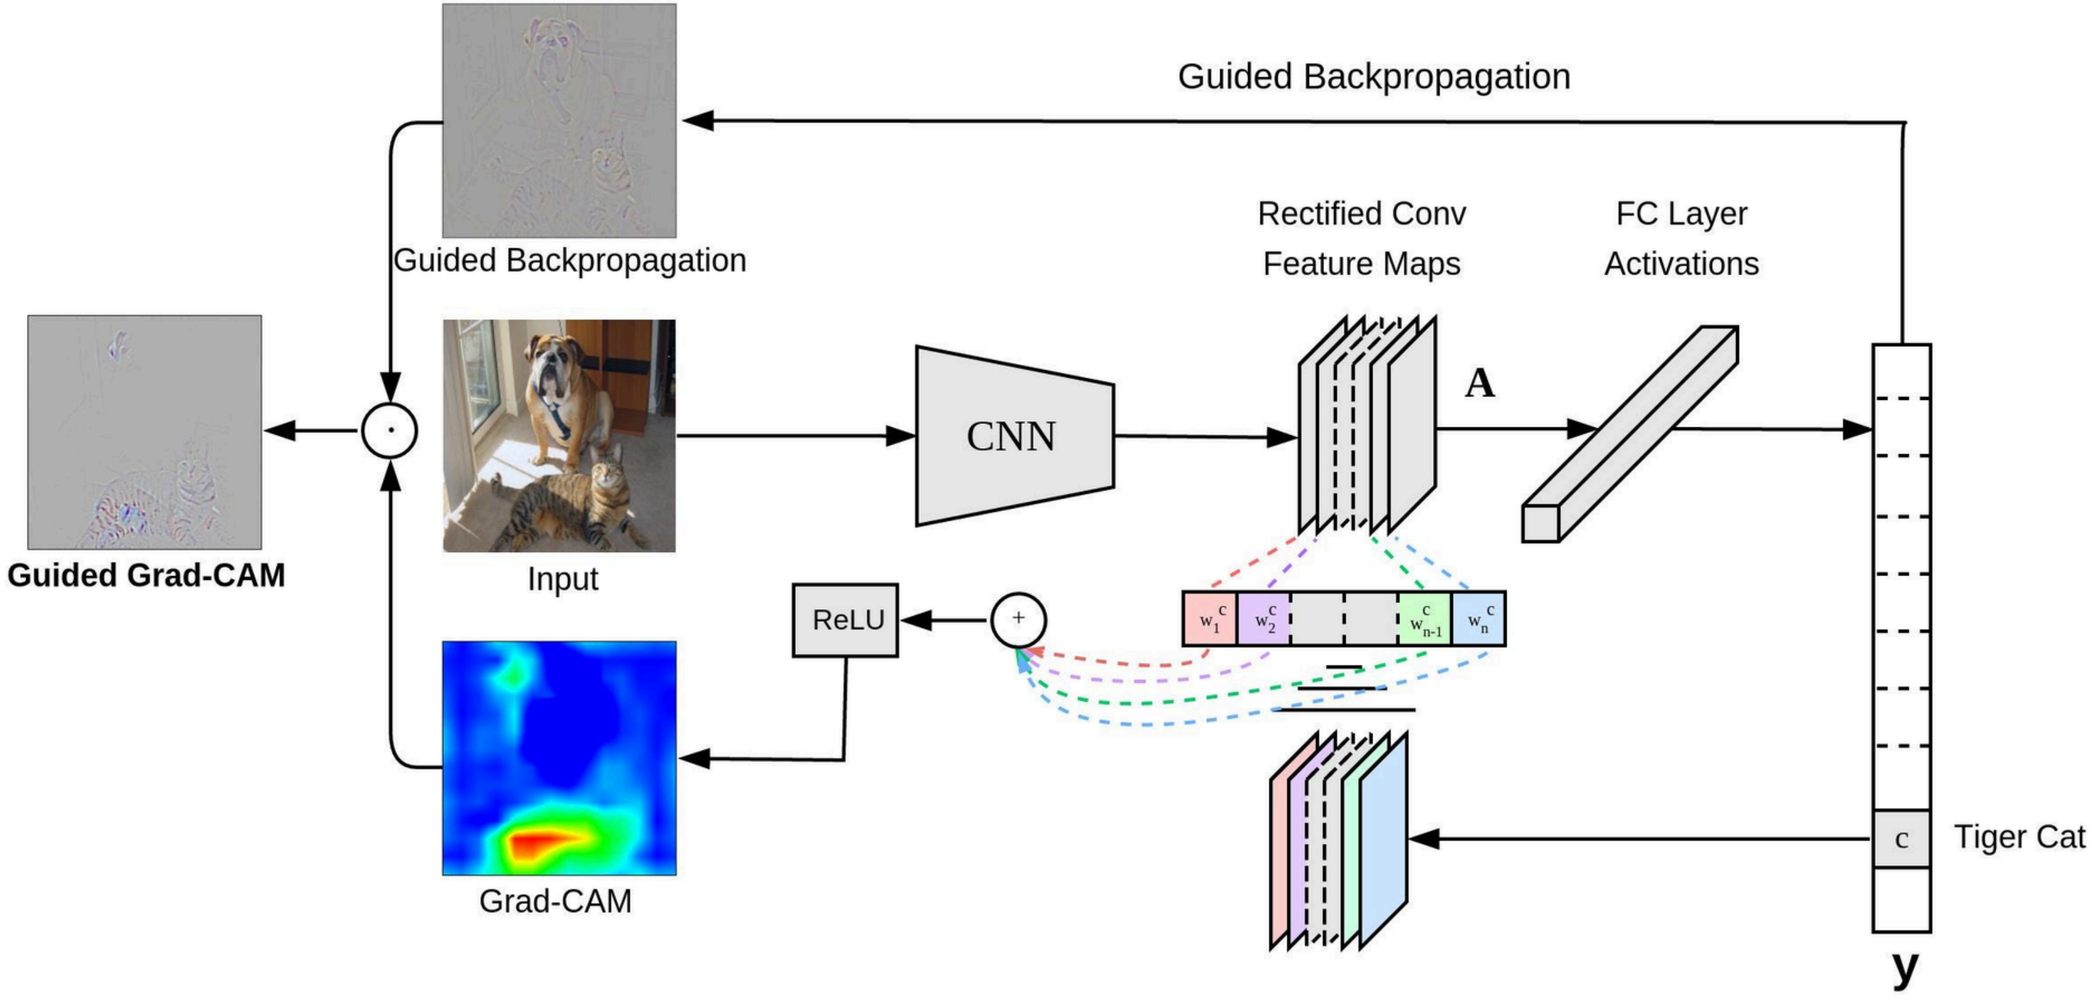
Guided Backpropagation
Guided Backpropagation
Rectified Conv
Feature Maps
FC Layer
Activations
A
CNN
Guided Grad-CAM
Input
ReLU
+
Grad-CAM
c
Tiger Cat
y

GRADCAM++

$$\alpha_{ij}^{kc} = \frac{\left(\frac{\partial S^c}{\partial A_{ij}^k}\right)^2}{2\left(\frac{\partial S^c}{\partial A_{ij}^k}\right)^2 + \sum_a \sum_b A_{ab}^k \left(\frac{\partial S^c}{\partial A_{ij}^k}\right)^3}$$

$$w_k^c = \sum_i \sum_j \alpha_{ij}^{kc} . relu\left(\frac{\partial Y^c}{\partial A_{ij}^k}\right)$$

$$L_{ij}^c = \sum_k w_k^c . A_{ij}^k$$

GRADCAM - ZASTOSOWANIA I OGRANICZENIA

ZASTOSOWANIA

- WIZUALIZACJA DECYZJI CNN
- DIAGNOSTYKA MEDYCZNA
- BADANIA NAD INTERPRETOWALNOŚCIĄ MODELI AI

OGRANICZENIA

- MAPA CIEPLNA NIE WSKAZUJE DOKŁADNEJ PRZYCZYNY DECYZJI, TYLKO OBSZARY ISTOTNE,
- ROZDZIELCZOŚĆ OGRANICZONA PRZEZ OSTATNIĄ WARSTWĘ KONWOLUCYJNĄ
- WYMAGA DOSTĘPU DO GRADIENTÓW

Źródło: Selvaraju et al. "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization", ICCV 2017

GRADCAM - PRZYKŁAD DZIAŁANIA

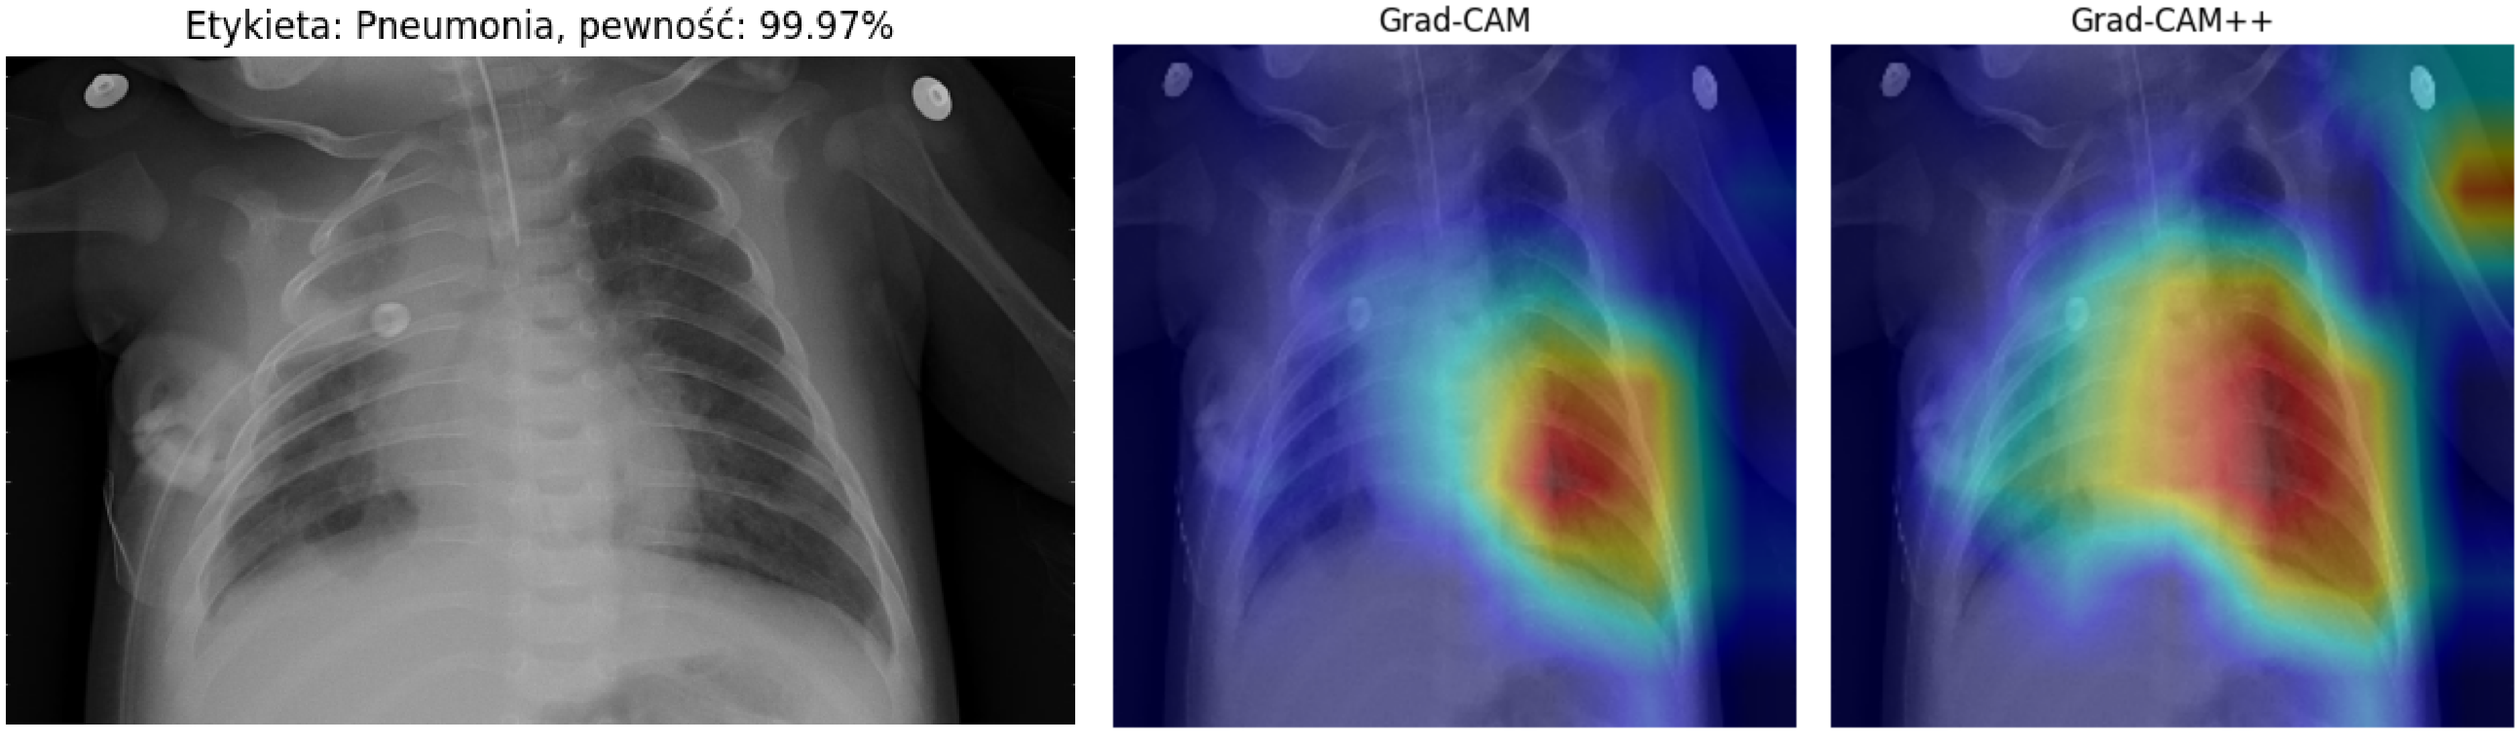

LIME – LOCAL INTERPRETABLE MODEL-AGNOSTIC EXPLANATIONS

1 PERTURBACJA

2 PREDYKCJE

3 APROKSYMACJA

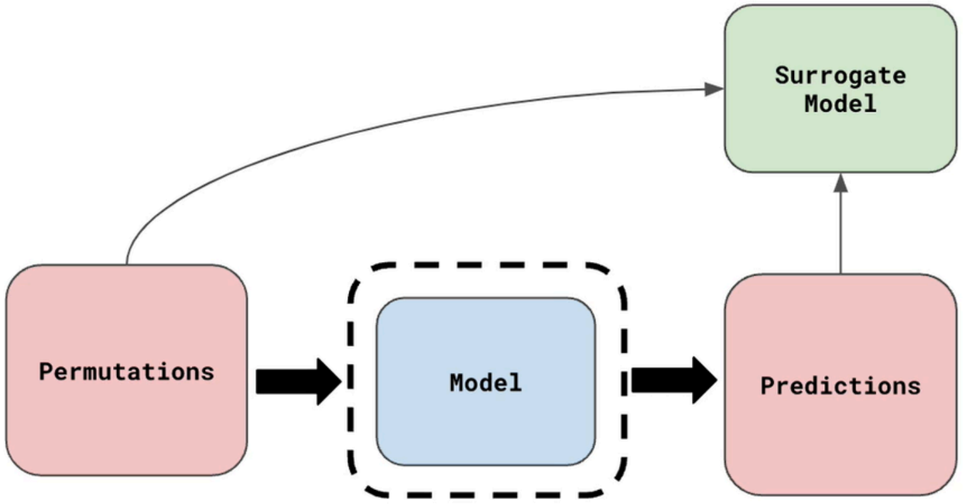

LIME – LOCAL INTERPRETABLE MODEL-AGNOSTIC EXPLANATIONS

ZALETY

- DZIAŁA DLA DOWOLNEGO MODELU ML
- NIE WYMAGA DOSTĘPU DO STRUKTURY MODELU
- LOKALNA INTERPRETACJA - WYJAŚNIA KONKRETNĄ PREDYKCJĘ DLA POJEDYNCZEJ OBSERWACJI
- PROSTOTA INTERPRETACJI
- MOŻE BYĆ STOSOWANY DO RÓŻNYCH TYPÓW DANYCH (TABELARYCZNE, OBRAZY)

WADY

- NIESTABILNOŚĆ WYNIKÓW
- TYLKO LOKALNE WYJAŚNIENIE
- WRAŻLIWOŚĆ NA SPOSÓB GENEROWANIA PERTURBACJI
- PROBLEMY PRZY DUŻEJ LICZBIE CECH
- BRAK GWARANCJI TEORETYCZNEJ OPTYMALNOŚCI

Źródło: Ribeiro et al. "Why Should I Trust You?", KDD/SIGKDD 2016

SHAP – SHAPLEY ADDITIVE EXPLANATIONS

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} \left[f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S) \right].$$

LOKALNA DOKŁADNOŚĆ

$$f(x) = \phi_0 + \Sigma\, \phi_i(x)$$

SUMA WARTOŚCI SHAPLEYA RÓWNA SIĘ PREDYKCJI MODELU

POMINIĘCIE CECHY

CECHA NIEOBECNA W MODELU MA ZEROWĄ WARTOŚĆ SHAPLEYA

SPÓJNOŚĆ

JEŚLI ZMIANA MODELU ZWIĘKSZA WKŁAD CECHY, JEJ WARTOŚĆ SHAPLEYA NIE MALEJE

SHAP – SHAPLEY ADDITIVE EXPLANATIONS

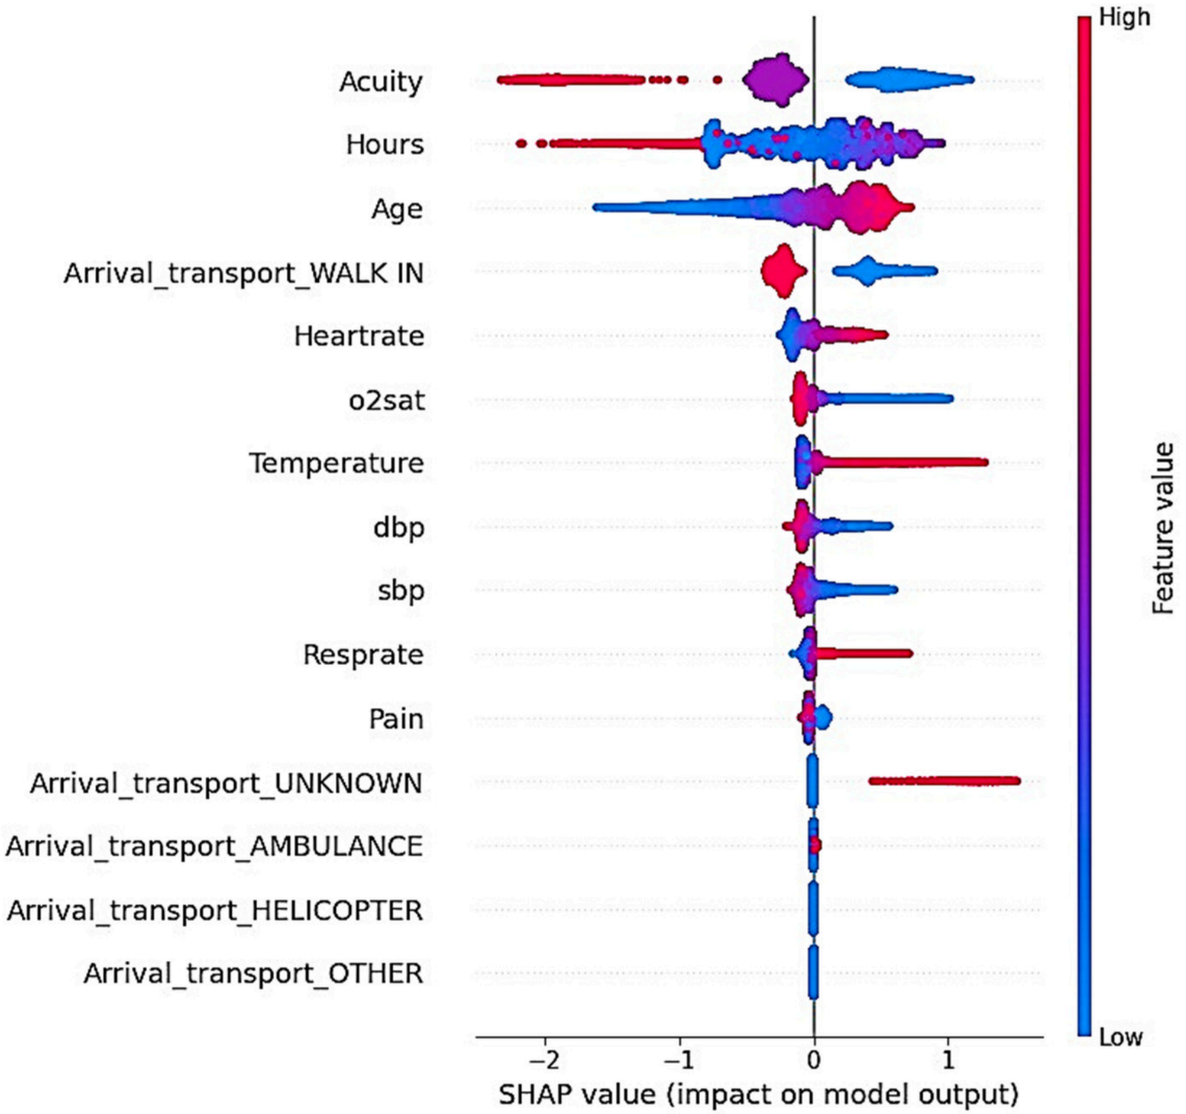

Źródło: https://www.mdpi.com/2076-3417/14/13/5925

PORÓWANIE METOD

Kryterium	GradCAM	LIME	SHAP
Typ danych	Obrazy (CNN)	Dowolny	Dowolny
Zasięg wyjaśnienia	Lokalne	Lokalne	Lokalne + Globalne
Podstawa teoretyczna	Gradienty CNN	Regresja lokalna	Teoria gier (Shapley)
Prędkość	Szybki	Średni	Zależy od wariantu
Gwarancje matematyczne	Brak	Brak	Posiada
Zrozumiałość wizualna	Wysoka (heatmapa)	Wysoka (bary)	Wysoka (bary/swarm)

BIBLIOGRAFIA

- RIBEIRO, M. T., SINGH, S., & GUESTRIN, C. (2016). "WHY SHOULD I TRUST YOU?": EXPLAINING THE PREDICTIONS OF ANY CLASSIFIER. IN PROCEEDINGS OF THE 22ND ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING (KDD), AUGUST 2016, PP. 1135–1144.
- SELVARAJU, R. R., COGSWELL, M., DAS, A., VEDANTAM, R., PARIKH, D., & BATRA, D. (2017). GRAD-CAM: VISUAL EXPLANATIONS FROM DEEP NETWORKS VIA GRADIENT-BASED LOCALIZATION. IN PROCEEDINGS OF THE IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV), OCTOBER 2017, PP. 618–626.
- LUNDBERG, S. M., & LEE, S.-I. (2017). A UNIFIED APPROACH TO INTERPRETING MODEL PREDICTIONS. IN ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS), VOL. 30, DECEMBER 2017, PP. 4765–4774.
- CHATTOPADHAY, A., SARKAR, A., HOWLADER, P., & BALASUBRAMANIAN, V. N. (2018). GRAD-CAM++: GENERALIZED GRADIENT-BASED VISUAL EXPLANATIONS FOR DEEP CONVOLUTIONAL NETWORKS. IN 2018 IEEE WINTER CONFERENCE ON APPLICATIONS OF COMPUTER VISION (WACV), LAKE TAHOE, NV, USA, PP. 839–847.